


## Anexo A · Arquitectura detallada del harness

**El modelo propone; el código decide.** Los roles entregan por tools con schema; qué entra en SQLite, qué capítulo se acepta y qué versión se publica lo deciden validadores deterministas y una máquina de estados en código.

### A.1 Vista general

Un solo proceso uvicorn: la API, la cola y el worker comparten memoria, y por eso el techo de tokens es un contador global.



### A.2 Los siete roles

Cada rol es una sesión del Agent SDK con un prompt, una tool de entrega, una lista blanca de tools y límites de turnos. Las tools integradas de Claude Code están desactivadas: ningún rol lee ficheros ni ejecuta órdenes.


| Rol            | Modelo    | Recibe                                                                   | Tool                                                   | Produce                                                                 |
|----------------|-----------|--------------------------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------------------------------|
| Entrevistador  | Haiku 4.5 | Historial, brief en curso, hechos verificados, comprobaciones calculadas | <code>update_brief</code>                              | Brief en borrador                                                       |
| Extractor      | Haiku 4.5 | Un texto libre, como dato                                                | <code>submit_facts</code>                              | Hechos con cita literal                                                 |
| Planner        | Sonnet 5  | Brief sin textos libres, story bible inicial, catálogo de tropos         | <code>submit_plan</code> · <code>propose_change</code> | Mundo, reparto, outline, StyleSheet, título · propuesta de cambio       |
| Writer         | Haiku 4.5 | Su ventana (A.4); en reescritura, los defectos                           | <code>submit_chapter</code>                            | Texto y título del capítulo                                             |
| Editor         | Haiku 4.5 | Capítulo, rúbrica, StyleSheet, beats, CanonCards, resúmenes              | <code>submit_review</code>                             | Puntuación 1–5 por criterio, defectos, usos de hechos, eventos, resumen |
| Juez           | Sonnet 5  | Novela entera, story bible compacta, rúbrica, catálogo de tropos         | <code>submit_evaluation</code>                         | Puntuación 1–5 por criterio, con capítulos citados                      |
| Revisor visual | Haiku 4.5 | Vista de la versión                                                      | <code>submit_visual_review</code>                      | Recortado en esta entrega                                               |


- **Writer y editor separados:** quien escribe no se evalúa; el editor nunca ve el razonamiento del writer.
- **El editor critica y registra, no reescribe:** corregir es escribir, y lo hace el writer con los defectos.
- **Ningún rol escribe canon:** el código aplica el plan, la aceptación de cada capítulo y los cambios, cada uno en una transacción.

### A.3 El bucle de un capítulo

Ordenado de barato a caro: un capítulo que no pasa los hooks no consume una sesión de editor.








| Límite                               | Valor             |
|--------------------------------------|-------------------|
| Reintentos por capítulo              | 3                 |
| Reintentos del plan                  | 2                 |
| Ciclos de reescritura del gate       | 2                 |
| Propuestas de cambio inválidas       | 2                 |
| Reanudaciones por ejecución          | 3                 |
| Techo de tokens concurrentes         | 100.000           |
| Espera máxima en la API por el techo | 30 s, después 503 |

## A.4 Qué lee el writer en el capítulo N


El contexto se construye, no se acumula: el orquestador ensambla la ventana antes de abrir cada sesión y ningún rol pide contexto. La ventana tiene un tamaño casi constante sea cual sea N.



| Rol    | Residentes                                                                                                 | Recupera por RAG                                       |
|--------|------------------------------------------------------------------------------------------------------------|--------------------------------------------------------|
| Writer | StyleSheet, proyección del outline, resúmenes 1..N-1, final de N-1, obligatorios de N, hechos de sus beats | Sí, consulta prospectiva (los beats que va a escribir) |
| Editor | StyleSheet, resúmenes 1..N-1, beats de N, rúbrica                                                          | Sí, consulta retrospectiva (el texto escrito)          |
| Juez   | — (recibe la novela entera, ~22k tokens)                                                                   | No                                                     |


- Los resúmenes son residentes: diez caben enteros, y recuperarlos por similitud sería elegir algo que ya cabe.
- El writer nunca recibe prosa recuperada: tiende a imitarla y aumentaría la repetición.
- Dos consultas distintas dan a writer y editor puntos ciegos distintos.

## A.5 RAG híbrido de una colección, sin re-ranking



- **Unidad:** la CanonCard, tarjeta de texto generada por código a partir de una entidad (personaje con sus hechos y eventos, lugar, novum). Al aceptar un capítulo, cada entidad con novedades recibe una tarjeta sucesora; las tarjetas no se editan.
- **Corte temporal antes de puntuar:** es una cláusula de la consulta, no una instrucción al modelo. Sin él, el editor del capítulo 3 vería la verdad del 9.
- **Sin re-ranking:** con vectores fijos y desempate estable, el recuperador es determinista y se prueba sin modelo («la ventana del capítulo 4 contiene la tarjeta X y no la Y»).
- **Una transacción:** story bible e índice se escriben juntos; nunca discrepan.

### A.6 Gate de publicación



| Fallo                                         | Atribuido a                                     | Acción                                                   |
|-----------------------------------------------|-------------------------------------------------|----------------------------------------------------------|
| Elemento obligatorio sin uso                  | Capítulos que el outline le asignó              | Reescritura dirigida                                     |
| Nombre no canónico o prohibida en un capítulo | Ese capítulo                                    | Reescritura dirigida                                     |
| Invariante Lean violado                       | Capítulos de los eventos del testigo            | Reescritura dirigida                                     |
| Criterio bloqueante del juez bajo umbral      | Capítulos que el juez cita (su schema lo exige) | Reescritura dirigida                                     |
| Testigo Lean solo con eventos del brief       | Nadie: solo el cliente puede cambiar el brief   | <code>failed</code> , <code>unattributable_defect</code> |
| Enlace del PDF que no resuelve                | Nadie: es código                                | <code>failed</code> , <code>render_failure</code>        |