

Anexo C · Tabla completa de resultados de evals

Fuente: `story-maker evals table`, generado en la máquina con sesión de Claude Code (única que ejecuta generación real), snapshot del **2026-09-25**, commit `bd1a994`. Ninguna prueba ni la CI llaman a un modelo (`docs/verification.md` §4.2); esta tabla sale de las cinco ejecuciones reales de evals sobre `ejemplos/briefs/`.

Aviso de honestidad. Snapshot **antes de cualquier publicación**: de los cinco briefs, ninguno llegó a `published`. Lean bloqueó las 3 candidatas que sí alcanzaron el gate (3/3). Esta tabla documenta el estado del tuning en curso (iteración de prompt del writer v1 → v3), no un resultado final ni una demostración de éxito.

Leyenda de las celdas

Tomada de `docs/verification.md` §4.2 y de `backend/src/story_maker/observability/scores.py` (los 18 nombres de score canónicos; TLC/ `harness-tla` no envía score).

- **Bloqueantes por capítulo** (`outline`, `longitud-capitulo`, `nombres-exactos`, `palabras-prohibidas`, `elementos-obligatorios`, `cronologia-lean`): `pasa · d o falla · d`, con *d* = intentos rechazados por ese validador antes del resultado final. En una versión publicada todo bloqueante pasa por construcción — la información está en lo que cazó antes de eso.
- **Semánticos** (`rubrica-capitulo`, `juez-novela`): media de sus criterios, con el criterio mínimo entre paréntesis. Escala 1–5.
- **citas-verificadas**: número de hechos extraídos del texto libre y descartados por no tener cita literal que los respalde.
- **Detector de inyección / hook de policy**: cuentas de `audit_log` (flags de inyección marcados; denegaciones del `PreToolUse` de policy), no scores 1–5.
- **n/a**: el validador no llegó a ejecutarse porque la ejecución terminó antes (brief `queued` o `failed` en un punto anterior).
- Filas sin dato en este snapshot (el validador no forma parte de esta extracción parcial, o depende de una versión publicada que aún no existe): *sin dato*.

Briefs: **1** ejemplo · **2** infantil · **3** boda/aniversario · **4** adversarial · **5** incoherencia temporal (`docs/verification.md` §4.2, tabla "qué debería ejercitar cada brief").

(a) Resultados brief × validador

Validador	1 ejemplo	2 infantil	3 boda	4 adversarial	5 temporal
schema-brief	sin dato	sin dato	sin dato	sin dato	sin dato
citas-verificadas (hechos descartados)	0	0	0	0	0
schema-salida	sin dato	sin dato	sin dato	sin dato	sin dato
outline	pasa · 0	pasa · 1	pasa · 0	pasa · 0	pasa · 0
longitud-capitulo	pasa · 2	pasa · 6	pasa · 2	pasa · 0	pasa · 3
nombres-exactos	pasa · 6	pasa · 14	pasa · 4	pasa · 0	pasa · 0
palabras-prohibidas	pasa · 0	pasa · 0	pasa · 0	n/a	n/a
elementos-obligatorios	pasa · 0	pasa · 0	pasa · 0	n/a	n/a
rubrica-capitulo	5,0 (5)	3,8 (2)	4,0 (2)	4,8 (4)	4,0 (1)
juez-novela	3,7 (1)	4,4 (2)	4,0 (2)	n/a	n/a
cronologia-lean	falla · 1	falla · 1	falla · 1	n/a	n/a
revision-visual	sin dato	sin dato	sin dato	sin dato	sin dato
pdf-enlaces	sin dato	sin dato	sin dato	sin dato	sin dato
linter-repeticion	sin dato	sin dato	sin dato	sin dato	sin dato
linter-legibilidad	sin dato	sin dato	sin dato	sin dato	sin dato
linter-estilo-ia	sin dato	sin dato	sin dato	sin dato	sin dato
linter-consistencia	sin dato	sin dato	sin dato	sin dato	sin dato
Detector de inyección (flags en audit_log)	0	0	0	3	0
Hook de policy (denegaciones en audit_log)	6	1	13	0	1
revision-humana	sin dato (l, pendiente de sesión con el usuario)	—	—	—	—

Ninguno de los cinco alcanzó `published` ; por eso `schema-salida` , `revision-visual` , `pdf-enlaces` y los cuatro linters de prosa —validadores del artefacto final o que corren sobre la versión ya montada— no tienen dato en este snapshot, y no se ha inventado un valor para ellos.

(b) Resumen por brief

Métrica	1 ejemplo	2 infantil	3 boda	4 adversarial	5 temporal
Estado final	running	failed (retries_exhausted)	failed (retries_exhausted)	queued	failed (retries_exhausted)
Capítulos aceptados al primer intento	7	2	5	1	4
Ciclos de gate	1	1	1	0	0
Tokens de entrada	847	1.224	1.158	58	792
Tokens de salida	372.438	502.587	424.333	61.215	346.471
Coste USD (Langfuse, precio de lista)	3,5781	4,8250	3,9418	0,6997	3,2501
Latencia total	4.049.497 ms (≈ 67 min)	5.312.293 ms (≈ 89 min)	4.651.561 ms (≈ 78 min)	573.530 ms (≈ 10 min)	3.658.830 ms (≈ 61 min)
Pico de tokens concurrentes reservados (techo 100.000)	28.246	24.394	26.562	11.734	21.733
Prompts con etiqueta explícita	2	1	1	1	2
Traza Langfuse	run:16	run:12	run:13	run:14	run:15

(«Prompts con etiqueta explícita»: cuenta de prompts servidos por Langfuse con `Label` versionado en esa ejecución, según el dato de la tabla; este anexo no infiere a qué versión de `writer` corresponde cada cuenta — ver Anexo H para el mecanismo de etiquetado.)

El brief 4 (adversarial) quedó `queued` : la carta con instrucciones dirigidas al sistema activó el detector de inyección (3 flags) antes de consumir una sesión completa de generación — coherente con el diseño (`docs/verification.md` §4.2, tabla "qué debería ejercitar cada brief": "nada llega al brief ni a la novela").

Iteración de tuning (`docs/verification.md` §4.2(c))

Disparador común: en 020-C10 (ejecuciones 1–5), `longitud-capitulo` falla en los 5 briefs y ninguna novela llega al gate.

Iteración 1 — `writer v1` → `v2`

Campo	Valor
Fecha · commit	2026-09-25 · <code>cf6b5e4</code> , <code>ff129b7</code>
Disparador	<code>longitud-capitulo</code> en <code>falla</code> en los briefs 1–5 (2, 5, 5, 3 y 3 rechazos); 5 <code>failed (retries_exhausted)</code> . Entregas de 666 a 1.194 palabras con objetivo 1.100–1.250
Hipótesis	El <code>writer</code> (Haiku 4.5) subestima la extensión; repartir <code>target_words</code> por beat y contar en párrafos
Cambio	prompt <code>writer</code> <code>v1</code> → <code>v2</code> en Langfuse
Control	los 5 briefs (antes = ejecuciones 1–5) → después = ejecuciones 6–10, misma config

Métrica	Antes (v1)	Después (v2)	Δ
Capítulos aceptados al primer intento	1	0	-1
Entregas en rango de longitud-capitulo	8 de 26 (media 945)	11 de 28 (media 979)	+3 (+34 palabras)
Novelas publicadas	0	0	0
Coste USD por novela (media)	0,73	0,86	+0,13

Efecto insuficiente: la extensión apenas se mueve.

Iteración 2 — writer v2 → v3

Campo	Valor
Fecha · commit	2026-09-25 · 0455b81
Disparador	Iteración 1: entregas de 674 a 1.226 palabras, 5 failed
Hipótesis	Haiku 4.5 entrega ~25 % menos de lo que cree; target_words + 200 y al menos 14 párrafos compensa el sesgo. El writer sigue en Haiku por decisión del usuario (cuota, architecture.md \$18)
Cambio	prompt writer v2 → v3 en Langfuse
Control	los 5 briefs → después = ejecuciones 11–16. Desde la 12, la lista de prohibidas de nivel user del brief boda solo está activa durante su ejecución — la 11 (brief 1) cayó por una prohibida de otro cliente que se filtró («pantalla»), fallo corregido en 020-C18

Métrica	Brief	Antes (v2)	Después (v3)	Δ
Entregas en rango de longitud-capitulo	1	0 de 2 (media 858)	5 de 6 (media 1.375)	+5 (+517 palabras)
Novelas publicadas	1–5	0	en curso (esta tabla)	—
Coste USD por novela	1	0,52	1,28 (hasta el capítulo 4)	—

La tabla (a)/(b) de este anexo corresponde a las trazas run:12 – run:16 , tomadas en el mismo snapshot (2026-09-25, commit bd1a994) que la iteración 2 de tuning describe como «en curso»; no se afirma aquí en qué versión de writer corrió cada una más allá de lo que ya documenta la sección de iteración anterior.