

Anexo G · Modelos y proveedores de LLM considerados

G.1 Modelo por rol

Criterio: calidad donde se planifica o se juzga la novela entera; modelo ligero en el resto, por coste y por cuota.
Asignación provisional hasta la iteración de tuning.

Modelo	Precio de lista (entrada / salida, \$/M)	Roles	Motivo
Claude Sonnet 5	2 / 10	Planner, juez	Planifican o juzgan la novela entera; el juez hace de filtro de calidad
Claude Haiku 4.5	1 / 5	Writer, editor, entrevistador, extractor, revisor visual	Tareas acotadas por capítulo o por turno; el writer, el rol que más tokens gasta, pasó a Haiku por cuota
Claude Opus 5.5	4 / 20	Ninguno	+2,96 €/novela si sustituye a Sonnet; el margen baja al 54 % (Anexo E)

G.2 Proveedor con 0 € en desarrollo

Criterio: 0 € en créditos de API, calidad suficiente y tool calling fiable con el Claude Agent SDK.

Opción	Decisión	Motivo
Login de Claude Code de la máquina	Elegido	0 €, tool calling fiable, mismas funciones que la API (hooks, skills, tools)
OpenRouter con modelos gratuitos	Descartado	~50 peticiones al día: no alcanza para 10 capítulos con reintentos
Ollama local	Descartado	Calidad y tool calling no garantizados con el Agent SDK en el portátil
Gemini gratis con proxy LiteLLM	Descartado	Añade un proxy y el tool calling con el Agent SDK no está garantizado

El proveedor es configurable (`LLM_PROVIDER=anthropic_compatible` apunta a la API de Anthropic u otro endpoint compatible): es el camino a producción sin tocar los roles. El coste de la propuesta se calcula siempre a precio de lista de la API.